



(12) 发明专利申请

(10) 申请公布号 CN 115112264 A

(43) 申请公布日 2022. 09. 27

(21) 申请号 202210728322.2

(22) 申请日 2022.06.24

(71) 申请人 国家粮食和物资储备局科学研究院
地址 100032 北京市西城区百万庄大街11号

(72) 发明人 苑江浩 汪忠明

(74) 专利代理机构 北京智行阳光知识产权代理
事务所(普通合伙) 11738
专利代理师 杨赛峰

(51) Int. Cl.

G01K 13/00 (2021.01)

G06K 9/62 (2022.01)

G06N 3/00 (2006.01)

G06N 3/04 (2006.01)

G06N 3/08 (2006.01)


权利要求书2页 说明书8页 附图5页

(54) 发明名称

一种基于改进的GRU粮堆单点温度预测方法

(57) 摘要

本发明提供了一种基于改进的GRU粮堆单点温度预测方法,涉及粮食安全储存领域,本发明实时采集粮情数据,而粮情数据包括大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 、粮仓湿度 M_g 以及粮堆单点温度 t ,对粮情数据进行处理,初始化GRU网络模型,引入果蝇优化算法优化GRU网络模型的网络权值,建立改进的GRU粮堆单点温度预测模型;进而输出得到预测粮堆单点温度;本发明充分考虑粮堆温度的非线性、时序性等特点,且相较于LSTM网络模型运算代价低,同时引入了果蝇优化算法优化GRU网络权值,实现最优模型参数的自动获取;本发明不再面向传统的粮堆平均温度或各层平均温度,而是针对粮堆单点温度预测。



1. 一种基于改进的GRU粮堆单点温度预测方法,其特征在于,包括以下步骤:

S1、实时采集粮情数据;粮情数据包括大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 、粮仓湿度 M_g 以及粮堆单点温度 t ;

埋设在粮堆内的温度传感器实时采集埋设点位的粮堆单点温度 t ,而粮仓内的温度传感器和湿度传感器实时采集粮仓内的粮仓温度 T_g 和粮仓湿度 M_g ,同时小型气象站采集大气温度 T_a 和大气湿度 M_a ;

S2、对步骤S1采集的粮情数据进行异常值识别以及缺失值弥补;

S3、将大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 和粮仓湿度 M_g 分别与粮堆单点温度 t 进行相关性分析;

S4、粮情数据进行归一化处理,并划分训练集、验证集和测试集;

S5、初始化GRU网络模型,引入果蝇优化算法优化GRU网络模型的网络权值,建立改进的GRU粮堆单点温度预测模型;

S6、利用测试集进行GRU粮堆单点温度预测模型的验证与测试,并输出得到预测粮堆单点温度。

2. 根据权利要求1所述的一种基于改进的GRU粮堆单点温度预测方法,其特征在于,步骤S2包括以下步骤:

S2.1、针对步骤S1采集的大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 、粮仓湿度 M_g 以及粮堆单点温度 t ,逐个进行异常值识别并剔除;

S2.2、对步骤S3.1识别并剔除的缺失值进行弥补。

3. 根据权利要求2所述的一种基于改进的GRU粮堆单点温度预测方法,其特征在于,步骤S2.1具体包括以下内容:

在检测异常中,如果粮情数据在 $(\mu-3\sigma, \mu+3\sigma)$ 之间区域内,则粮情数据处于正常范围内;反之表示异常,需进行识别并剔除;

其中 μ 为粮情数据的平均值, σ 为标准差。

4. 根据权利要求3所述的一种基于改进的GRU粮堆单点温度预测方法,其特征在于,步骤S2.2包括以下步骤:

采用样条插值法(spline)对步骤S3.1中缺失的粮情数据进行插补,公式如下:

$$A(x) = y_i \times \phi_0 \times \left(\frac{x - x_i}{d_i} \right) + y_{i+1} \times \phi_0 \times \left(\frac{x_{i+1} - x}{d_i} \right) + m_i \times d_i \times \phi_1 \times \left(\frac{x - x_i}{d_i} \right) - m_{i+1} \times d_i \times \phi_1 \times \left(\frac{x_{i+1} - x}{d_i} \right), i = 0, 1, 2, \dots, 9$$

采用单点前后各5个的温度值进行插值,即10个时间的温度值,其中 $x \in \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$, $d_i = x_{i+1} - x_i$, $\phi_0(x) = (2 \times x + 1) \times (x - 1)^2$, $\phi_1(x) = x \times (x - 1)^2$, $A(x)$ 为插值结果, y_i 表示 x_i 所对应的温度值。

5. 根据权利要求4所述的一种基于改进的GRU粮堆单点温度预测方法,其特征在于,步骤S3采用皮尔逊相关系数,分别计算采集到的大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 以及粮仓湿度 M_g 与粮堆单点温度 t 的相关系数 r ,计算公式如下:

$$r = \frac{\sum_{k=1}^n (v_k - \bar{v})(t_k - \bar{t})}{\sqrt{\sum_{k=1}^n (v_k - \bar{v})^2} \sqrt{\sum_{k=1}^n (t_k - \bar{t})^2}}$$

其中 v 在计算过程中分别表示大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 以及粮仓湿度 M_g , $\bar{t}$ 表示原始温度序列数据的平均值, v_k 根据在计算过程中, 分别表示第 k 天的大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 和粮仓湿度 M_g , t_k 表示第 k 天的粮堆单点温度。

6. 根据权利要求5所述的一种基于改进的GRU粮堆单点温度预测方法, 其特征在于, 步骤S4包括以下步骤:

对经过步骤S3处理的粮情数据进行标准化处理, 公式如下:

$$t^* = \frac{t - \bar{t}}{t_{std}}$$

其中, t^* 为标准化后的数据, t_{std} 表示原始序列数据的标准差, $\bar{t}$ 表示原始温度序列数据的平均值。

7. 根据权利要求6所述的一种基于改进的GRU粮堆单点温度预测方法, 其特征在于, 步骤S5包括以下步骤:

S5.1、设定GRU网络模型参数和初始化网络权值;

S5.2、划分训练集、验证集和测试集;

S5.3、初始化果蝇优化算法参数;

S5.4、利用果蝇的嗅觉, 赋予每个果蝇随机的方向和距离;

S5.5、计算果蝇当前位置距原点的位置 $Dist_i$ 以及味道浓度的判定值 S_i ;

S5.6、将计算所得味道浓度的判定值 S_i 代入味道浓度判断函数function, 计算出当前每个果蝇所在位置的味道浓度 $smell_i$;

S5.7、比较每个果蝇所在位置的味道浓度 $smell_i$, 找到当前果蝇种群中味道浓度最大的果蝇个体;

S5.8、确定味道浓度最大的果蝇个体所在位置(X,Y)以及当前的味道浓度值, 此时的位置记为最优个体位置, 味道浓度记为最佳浓度值, 利用果蝇的视觉, 所有果蝇向最优个体位置飞去, 更新种群的位置;

S5.9、迭代寻优, 迭代次数若小于最大迭代次数maxgen, 转到S5.3, 再判断当前最佳浓度值是否优于前一最佳浓度值, 若优于, 执行S5.7, 否则重复执行S5.3, 直至迭代次数达到最大迭代次数maxgen, 找到目标所在位置;

S5.10、将获取的最佳果蝇位置作为GRU网络模型的网络权值。

一种基于改进的GRU粮堆单点温度预测方法

技术领域

[0001] 本发明涉及粮食安全储存领域,尤其涉及一种基于改进的GRU粮堆单点温度预测方法。

背景技术

[0002] 在粮食产后储藏过程中会因虫害、粮食霉变等问题对粮食的质量和数量造成危害,粮堆温度是直接反应是否出现虫害或霉变等问题的重要因素,因此能够及时、有效、准确的实现对粮堆温度的预测对保障粮食安全至关重要。

[0003] 当前多为针对粮堆平均温度的预测技术,正如专利公开号CN112819221A,专利名称一种基于IPSO-GRU网络的粮情预测方法,该专利使用两层GRU网络 and 全连接层构建神经网络模型,使用粒子群算法优化神经网络的初始权重,在粒子群迭代过程中加入非线性惯性因子和自适应学习因子计算粒子的速度与位置,通过Dropout算法和RMSProp优化器训练网络,网络输出粮情预测结果;采用自学习性质的预测模型,利用粮情监测系统实时采集的粮情数据预测即将发生的储粮安全问题,有效弥补对粮情存储安全状态预警的不足,为粮情预测提供一种可靠的方法,但粮堆的平均温度并不能直接反映某一点的粮堆温度情况,由于粮仓的常用管理方式包括通风、空调和充氮控温等,当粮仓内个别点位出现超过阈值的高温趋势时,此时的预测的平均温度无法预知最高温度的实际情况,进而造成粮情误判,造成粮情隐患,且目前多采用支持向量机、BP神经网络等传统机器学习方法,这些方法在短期预测方面准确度较好,但对于长期的预测效果不佳。

[0004] 另外现有传统机器学习的方法不能有效的考虑粮堆温度变化的时序性、复杂性,具有一定的局限性,深度学习LSTM网络模型考虑了时序特征,但其存在两方面的问题,一是运算代价较高;二是其网络参数未进行优化,很难自动获取最优模型。

[0005] 本发明针对粮堆单点粮情预测研究方法缺失和长期预测精度不高等问题,提出一种改进的GRU网络模型用于粮情预测方法,弥补该领域的不足,为储粮单点粮情预测提供了技术支撑。

发明内容

[0006] 本发明所要解决的技术问题是克服现有技术中存在的不足,提供一种基于改进的GRU粮堆单点温度预测方法,其引入果蝇优化算法优化GRU网络模型的网络权值,建立改进的GRU粮堆单点温度预测模型;本发明不再面向传统的粮堆平均温度或各层平均温度,而是针对粮堆单点温度预测。

[0007] 本发明是通过以下技术方案予以实现:

[0008] 一种基于改进的GRU粮堆单点温度预测方法,包括以下步骤:

[0009] S1、实时采集粮情数据;粮情数据包括大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 、粮仓湿度 M_g 以及粮堆单点温度 t ;

[0010] 埋设在粮堆内的温度传感器实时采集埋设点位的粮堆单点温度 t ,而粮仓内的温

度传感器和湿度传感器实时采集粮仓内的粮仓温度 T_g 和粮仓湿度 M_g ,同时小型气象站采集大气温度 T_a 和大气湿度 M_a ;

[0011] S2、对步骤S1采集的粮情数据进行异常值识别以及缺失值弥补;

[0012] S3、将大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 和粮仓湿度 M_g 分别与粮堆单点温度 t 进行相关性分析;

[0013] S4、粮情数据进行归一化处理,并划分训练集、验证集和测试集;

[0014] S5、初始化GRU网络模型,引入果蝇优化算法优化GRU网络模型的网络权值,建立改进的GRU粮堆单点温度预测模型;

[0015] S6、利用测试集进行GRU粮堆单点温度预测模型的验证与测试,并输出得到预测粮堆单点温度。

[0016] 根据上述技术方案,优选地,步骤S2包括以下步骤:

[0017] S2.1、针对步骤S1采集的大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 、粮仓湿度 M_g 以及粮堆单点温度 t ,逐个进行异常值识别并剔除;

[0018] S2.2、对步骤S2.1识别并剔除的缺失值进行弥补。

[0019] 根据上述技术方案,优选地,步骤S2.1具体包括以下内容:

[0020] 在检测异常中,如果粮情数据在 $(\mu-3\sigma, \mu+3\sigma)$ 之间区域内,则粮情数据处于正常范围内;反之表示异常,需进行识别并剔除;

[0021] 其中 μ 为粮情数据的平均值, σ 为标准差。

[0022] 根据上述技术方案,优选地,步骤S2.2包括以下步骤:

[0023] 采用样条插值法(spline)对步骤S3.1中缺失的粮情数据进行插补,公式如下;

$$[0024] \quad A(x) = y_i \times \phi_0 \times \left(\frac{x - x_i}{d_i} \right) + y_{i+1} \times \phi_0 \times \left(\frac{x_{i+1} - x}{d_i} \right) + m_i \times d_i \times \phi_1 \times \left(\frac{x - x_i}{d_i} \right) - m_{i+1} \times d_i \times \phi_1 \times \left(\frac{x_{i+1} - x}{d_i} \right), i = 0, 1, 2, \dots, 9$$

[0025] 采用单点前后各5个的温度值进行插值,即10个时间的温度值,其中 $x \in \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$, $d_i = x_{i+1} - x_i$, $\phi_0(x) = (2 \times x + 1) \times (x - 1)^2$, $\phi_1(x) = x \times (x - 1)^2$, $A(x)$ 为插值结果, y_i 表示 x_i 所对应的温度值。

[0026] 根据上述技术方案,优选地,步骤S3采用皮尔逊相关系数,分别计算采集到的大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 以及粮仓湿度 M_g 与粮堆单点温度 t 的相关系数 r ,计算公式如下:

$$[0027] \quad r = \frac{\sum_{k=1}^n (v_k - \bar{v})(t_k - \bar{t})}{\sqrt{\sum_{k=1}^n (v_k - \bar{v})^2} \sqrt{\sum_{k=1}^n (t_k - \bar{t})^2}}$$

[0028] 其中 v 在计算过程中分别表示大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 以及粮仓湿度 M_g , $\bar{t}$ 表示原始温度序列数据的平均值, v_k 根据在计算过程中,分别表示第 k 天的大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 和粮仓湿度 M_g , t_k 表示第 k 天的粮堆单点温度。

[0029] 根据上述技术方案,优选地,步骤S4包括以下步骤:

[0030] 对经过步骤S3处理的粮情数据进行标准化处理,公式如下:

$$[0031] \quad t^* = \frac{t - \bar{t}}{t_{\text{std}}}$$

[0032] 其中, t^* 为标准化后的数据, t_{std} 表示原始序列数据的标准差, $\bar{t}$ 表示原始温度序列数据的平均值。

[0033] 根据上述技术方案, 优选地, 步骤S5包括以下步骤:

[0034] S5.1、设定GRU网络模型参数和初始化网络权值;

[0035] S5.2、划分训练集、验证集和测试集;

[0036] S5.3、初始化果蝇优化算法参数;

[0037] S5.4、利用果蝇的嗅觉, 赋予每个果蝇随机的方向和距离;

[0038] S5.5、计算果蝇当前位置距原点的位置 Dist_i 以及味道浓度的判定值 S_i ;

[0039] S5.6、将计算所得味道浓度的判定值 S_i 代入味道浓度判断函数 function , 计算出当前每个果蝇所在位置的味道浓度 smell_i ;

[0040] S5.7、比较每个果蝇所在位置的味道浓度 smell_i , 找到当前果蝇种群中味道浓度最大的果蝇个体;

[0041] S5.8、确定味道浓度最大的果蝇个体所在位置 (X, Y) 以及当前的味道浓度值, 此时的位置记为最优个体位置, 味道浓度记为最佳浓度值, 利用果蝇的视觉, 所有果蝇向最优个体位置飞去, 更新种群的位置;

[0042] S5.9、迭代寻优, 迭代次数若小于最大迭代次数 maxgen , 转到S5.3, 再判断当前最佳浓度值是否优于前一最佳浓度值, 若优于, 执行S5.7, 否则重复执行S5.3, 直至迭代次数达到最大迭代次数 maxgen , 找到目标所在位置;

[0043] S5.10、将获取的最佳果蝇位置作为GRU网络模型的网络权值。

[0044] 本发明的有益效果是:

[0045] (1) 本发明方法充分考虑粮堆温度的非线性、时序性等特点, 且相较于LSTM网络模型运算代价低, 同时引入了果蝇优化算法优化GRU网络参数, 实现最优模型参数的自动获取;

[0046] (2) 本发明相较于传统机器学习算法, 方法充分考虑了粮堆温度时序特性, 进而提升粮堆单点的温度预测精度;

[0047] (3) 本发明相较于研究对象, 本发明不再面向传统的粮堆平均温度或各层平均温度, 而是针对粮堆单点温度预测。

附图说明

[0048] 图1示出了根据本发明的实施例的流程示意图;

[0049] 图2示出了粮仓内水平切面的温度传感器布设示意图;

[0050] 图3示出了粮仓内垂直切面的温度传感器布设示意图;

[0051] 图4示出了检测点 $(10, 2, 1)$ 未来3天的训练过程情况;

[0052] 图5示出了检测点 $(10, 2, 1)$ 未来7天的训练过程情况;

[0053] 图6示出了检测点 $(9, 1, 2)$ 未来3天的训练过程情况;

[0054] 图7示出了检测点 $(9, 1, 2)$ 未来7天的训练过程情况;

- [0055] 图8示出了检测点(9,2,3)未来3天的训练过程情况;
- [0056] 图9示出了检测点(9,2,3)未来7天的训练过程情况;
- [0057] 图10示出了检测点(10,5,4)未来3天的训练过程情况;
- [0058] 图11示出了检测点(10,5,4)未来7天的训练过程情况;
- [0059] 图12示出了GRU结构图;

具体实施方式

[0060] 为了使本技术领域的技术人员更好地理解本发明的技术方案,下面结合附图和最佳实施例对本发明作进一步的详细说明。基于发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于发明保护的范围。

[0061] 在发明的描述中,需要说明的是,术语“中心”、“上”、“下”、“左”、“右”、“竖直”、“水平”、“内”、“外”等指示的方位或位置关系为基于附图所示的方位或位置关系,仅是为了便于描述发明和简化描述,而不是指示或暗示所指的装置或元件必须具有特定的方位、以特定的方位构造和操作,因此不能理解为对发明的限制。

[0062] 如图1所示,本发明提供了一种基于改进的GRU粮堆单点温度预测方法,本发明的应用对象为储藏在高大平方仓内的小麦和稻谷,粮堆内布有240个温度传感器,图2和图3为埋设的温度传感器布设情况图;粮堆内部的温度传感器布设总体为6行10列4层,由东向西分为10列,由南向北分为6行,粮堆自下而上分为4层,表层距粮面为0.3m,布点间隔约1.8m,底层距地面0.3m;同一层粮堆的温度传感器的列间距4.6m,两侧距墙0.5m;行间距4.8m,两侧距墙0.5m;同时在粮仓内设有采集粮仓温度和粮仓湿度的温度传感器和湿度传感器。

[0063] S1、实时采集粮情数据:埋设在粮堆内的温度传感器实时采集埋设点位的粮堆单点温度 t ,而粮仓内的温度传感器和湿度传感器实时采集粮仓内的粮仓温度 T_g 和粮仓湿度 M_g ,同时小型气象站采集大气温度 T_a 和大气湿度 M_a ,粮情数据包括大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 、粮仓湿度 M_g 以及粮堆单点温度 t ;

[0064] 本实施例的采集时间为2021年1月1日至2022年3月31日,数据采集频率为每天1次,一般为每天上午9时检测。同时记录粮食在储藏过程中采用的储藏工艺时间和方法,本试验仓全程也仅作常规的充氮控温和空调表层控温。

[0065] S2、对步骤S1采集的粮情数据进行异常值识别、处理以及缺失值弥补;

[0066] S2.1、针对大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 、粮仓湿度 M_g 以及粮堆单点温度 t ,逐个进行粮情数据的异常值识别;

[0067] 在检测异常中,如果粮情数据在 $(\mu-3\sigma, \mu+3\sigma)$ 之间区域内,则粮情数据处于正常范围内;反之表示异常,需进行剔除;

[0068] 其中 μ 为粮情数据的平均值, σ 为标准差,此处的粮情数据包括采集的大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 、粮仓湿度 M_g 以及粮堆单点温度 t ;

[0069] S2.2、对步骤S2.1识别并剔除的缺失值进行弥补;

[0070] 采用样条插值法(spline)对缺失的粮情数据进行插补,公式如下;

$$[0071] \quad A(x) = y_i \times \phi_0 \times \left(\frac{x - x_i}{d_i} \right) + y_{i+1} \times \phi_0 \times \left(\frac{x_{i+1} - x}{d} \right) + m_i \times d_i \times \phi_1 \times \left(\frac{x - x_i}{d_i} \right) - m_{i+1} \times d_i \times \phi_1 \times \left(\frac{x_{i+1} - x}{d_i} \right), i = 0, 1, 2, \dots, 9$$

[0072] 本发明采用单点前后各5个的温度值进行插值,即10个时间的温度值,其中 $x \in \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$, $d_i = x_{i+1} - x_i$, $\phi_0(x) = (2 \times x + 1) \times (x - 1)^2$, $\phi_1(x) = x \times (x - 1)^2$, $A(x)$ 为插值结果, y_i 表示 x_i 所对应的真实温度值;

[0073] S3、将大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 和粮仓湿度 M_g 分别与粮堆单点温度 t 进行相关性分析;

[0074] S3.1、采用皮尔逊相关系数,分别计算采集到的大气温度 T_a 和大气湿度 M_a 、粮仓温度 T_g 和粮仓湿度 M_g 与粮堆单点温度 t 的相关系数 r ,计算公式如下:

$$[0075] \quad r = \frac{\sum_{k=1}^n (v_k - \bar{v})(t_k - \bar{t})}{\sqrt{\sum_{k=1}^n (v_k - \bar{v})^2} \sqrt{\sum_{k=1}^n (t_k - \bar{t})^2}}$$

[0076] v 在计算过程中分别表示大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 以及粮仓湿度 M_g , $\bar{t}$ 表示原始温度序列数据的平均值,根据在计算过程中, v_k 分别表示第 k 天的大气温度 T_a 、大气湿度 M_a 、粮仓温度 T_g 以及粮仓湿度 M_g , t_k 表示第 k 天的粮堆单点温度;

[0077] S3.2、根据相关系数的表现,在单点温度预测中,大气温度 T_a 和粮仓温度 T_g 与粮堆单点温度 t 的相关系数更大,因此确定大气温度 T_a 和粮仓温度 T_g 作为后续的主要影响因素使用,而大气湿度 M_a 和粮仓湿度 M_g 作为次要影响因素使用;

[0078] S4、粮情数据进行归一化处理,并划分训练集、验证集和测试集;

[0079] 由于粮情数据包括大气温度 T_a 、粮仓温度 T_g 、大气湿度 M_a 和粮仓湿度 M_g 以及粮堆单点温度 t ,粮情数据的范围不同,为了降低由于数据尺度造成的影响,将粮情数据做标准化处理,公式如下:

$$[0080] \quad t^* = \frac{t - \bar{t}}{t_{std}}$$

[0081] 其中, t^* 为标准化后的数据, t_{std} 表示原始序列数据的标准差, $\bar{t}$ 表示原始温度序列数据的平均值;

[0082] S5、初始化GRU网络模型,引入果蝇优化算法优化GRU网络模型的网络权值,建立改进的GRU粮堆单点温度预测模型;

[0083] 初始化GRU网络模型是在LSTM模型的基础上合并遗忘门和输入门为更新门,使用单个门控单元同时控制遗忘因子和更新状态单元的决定,同时增加重置门。图12为GRU结构图,其公式如下;

$$[0084] \quad h_i^{(g-1)} = u_i^{(g-1)} \times h_i^{(g-1)} + (1 - u_i^{(g-1)}) \times \sigma \times \left(b_i + \sum_j U_{ij} \times x_j^{(g)} + \sum_j W_{ij} \times p_j^{(g-1)} \times h_j^{(g-1)} \right)$$

$$[0085] \quad u_i^{(g)} = \sigma \times \left(b_i^u + \sum_j U_{ij}^u \times x_j^{(g)} + \sum_j W_{ij}^u \times h_j^{(g)} \right)$$

$$[0086] \quad p_i^{(g)} = \sigma \times \left(b_i^p + \sum_j U_{ij}^p \times x_j^{(g)} + \sum_j W_{ij}^p \times h_j^{(g)} \right)$$

[0087] h_i 表示i时刻的记忆状态,x表示输入值, σ 表述Sigmoid函数, u_i 表示输入门神经元, p_i 表示重置门神经元,U、W、b为各个门神经元参数,在模型训练过程中获得。

[0088] LSTM和GRU两种模型工作原理基本相同,但相比于LSTM模型,GRU模型进一步简化,降低运行的计算代价,提高模型收敛速度;

[0089] S5.1、设定GRU网络模型参数,其中dorpout=0.2,recurrent_dropout=0.2,lookback=30,delay=7,epoch=20,优化算法使用RMSprop,输入层和隐含层节点数为32,输出层节点数为1;

[0090] S5.2、模型训练;以< $T_g, T_a, M_a, M_g, t, t1, t2, t3, t4, t5, t6, t7$ >的形式为一组数据读入,并将70%的数据作为训练集,20%的数据作为验证集以及10%的数据作为测试集,t1-t7表示未来第1-7天的单点温度值;

[0091] S5.3、初始化果蝇优化算法参数:种群大小sizepop,最大迭代次数maxgen,随机产生果蝇的初始位置(X_axis, Y_axis);

[0092] S5.4、利用果蝇的嗅觉,赋予每个果蝇随机的方向和距离,计算公式如下:

$$[0093] \quad \begin{cases} X_i = X_axis + RandomValue \\ Y_i = Y_axis + RandomValue \end{cases}$$

[0094] 其中RandomValue为搜索距离,搜索方向为随机数;

[0095] S5.5、计算果蝇当前位置距原点的位置 $Dist_i$ 以及味道浓度的判定值 S_i ;

$$[0096] \quad Dist_i = \sqrt{(X_i^2 + Y_i^2)}$$

$$[0097] \quad S_i = 1/Dist_i$$

[0098] S5.6、将计算所得味道浓度的判定值 S_i 代入味道浓度判断函数function,计算出当前每个果蝇所在位置的味道浓度smell_i;

$$[0099] \quad smell_i = function(S_i)$$

[0100] 味道浓度判断函数function采用真实值和预测值的均方误差MSE;

[0101] S5.7、比较每个果蝇所在位置的味道浓度smell_i,找到当前果蝇种群中味道浓度最大的果蝇个体;

[0102] S5.8、确定味道浓度最大的果蝇个体所在位置(X,Y)以及当前的味道浓度值,此时的位置记为最优个体位置,味道浓度记为最佳浓度值,利用果蝇的视觉,所有果蝇向最优个体位置飞去,更新种群的位置;

[0103] S5.9、迭代寻优,迭代次数若小于最大迭代次数maxgen,转到S5.3,再判断当前最佳浓度值是否优于前一最佳浓度值,若优于,执行S5.7,否则重复执行S5.3,直至迭代次数达到最大迭代次数maxgen,找到目标所在位置;

[0104] S5.10、将获取的最佳果蝇位置作为GRU网络模型的网络权值；

[0105] S6、利用测试集进行GRU粮堆单点温度预测模型的验证与测试，并输出预测得到粮情数据。

[0106] 模型输出结果的精度检验

[0107] 将通过均方误差 (MSE) 和平均绝对误差 (MAE) 衡量优化后GRU粮堆单点温度预测模型的效果，计算方式如下所示；当模型误差越大时，MSE和MAE的值越大。

$$[0108] \quad \text{MSE} = \frac{1}{m} \times \sum_{i=1}^m (I(x_i) - y_i)^2$$

$$[0109] \quad \text{MAE} = \frac{1}{m} \times \sum_{i=1}^m |I(x_i) - y_i|$$

[0110] 其中， m 为样本总数， $I(x_i)$ 表示预测值， y_i 表示 x_i 所对应的真实温度值；

[0111] 结果与分析

[0112] 单点温度预测结果分析

[0113] 采用改进的GRU模型对单点预测，分别预测各检测点未来3天、7天的温度，各检测点模型训练过程情况如图4-11所示。

[0114] 粮堆内单点温度预测因温度变化趋势较为明显更具有代表性，同时更加具备预测的价值，因此本发明从各层选取温度变化趋势较大的检测点实现单点预测，定义检测点(列数,行数,层数)，试验仓的检测点1-4分别为(10,2,1)、(9,1,2)、(9,2,3)、(10,5,4)，数据采用2021年1月1日至2022年3月31日共计455天的历史数据。

[0115] 如图4，对于检测点(10,2,1)，预测未来3天的温度时，训练集的MAE为0.075，MSE为0.01，验证集的MAE为0.15，MSE为0.03，温度的平均绝对误差为0.675℃；如图5，预测未来7天的温度时，训练集的MAE为0.06，MSE为0.01，验证集的MAE为0.2，MSE为0.06，温度的平均绝对误差为0.9℃。

[0116] 如图6，对于检测点(9,1,2)，预测未来3天的温度时，训练集的MAE为0.06，MSE为0.01，验证集的MAE为0.175，MSE为0.03，温度的平均绝对误差为0.91℃；如图7，预测未来7天的温度时，训练集的MAE为0.06，MSE为0.01，验证集的MAE为0.16，MSE为0.04，温度的平均绝对误差为0.832℃。

[0117] 如图8，对于检测点(9,2,3)，预测未来3天的温度时，训练集的MAE为0.05，MSE为0.01，验证集的MAE为0.15，MSE为0.08，温度的平均绝对误差为0.564℃；如图9，预测未来7天的温度时，训练集的MAE为0.06，MSE为0.01，验证集的MAE为0.15，MSE为0.07，温度的平均绝对误差为0.564℃。

[0118] 如图10，对于检测点(10,5,4)，预测未来3天的温度时，训练集的MAE为0.07，MSE为0.02，验证集的MAE为0.18，MSE为0.04，温度的平均绝对误差为0.621℃；如图11，预测未来7天的温度时，训练集的MAE为0.07，MSE为0.02，验证集的MAE为0.17，MSE为0.04，温度的平均绝对误差为0.587℃。

[0119] 从图4-11可以看出，本发明的预测模型表现良好，表现稳定，只有在表层的温度预测时会频繁波动(如图4和图5)，通过与底层(如图10和图11)情况对比，考虑是空调控温工

艺对表层的实际温度影响较大,会对模型产生一定的影响,但在空调控温达到恒定的效果后,模型表现逐步稳定。

[0120] 模型性能分析

[0121] 经测试集测试,模型稳定性较好,误差温度在0.45-0.89℃。因目前的研究缺少针对单点温度预测,但在平均温度预测研究领域已充分证明LSTM模型优于传统的SVM模型、BP神经网络模型和ARIMA时序模型,因此仅通过与LSTM模型的对比进一步验证模型的性能,实验结果对比如下表1所示,可以看出,本发明的预测模型和方法更加准确,且模型稳定性更高。

[0122] 表1实验结果

[0123]

检测点	评价标准				备注
	MSE		MAE		
	GRU	LSTM	GRU	LSTM	
(10, 2, 1)	0.04	0.05	0.16	0.2	未来3天
	0.06	0.06	0.16	0.25	未来7天
(9, 1, 2)	0.03	0.06	0.17	0.15	未来3天
	0.06	0.07	0.16	0.18	未来7天
(9, 2, 3)	0.06	0.08	0.15	0.16	未来3天
	0.07	0.09	0.15	0.19	未来7天
(10, 5, 4)	0.04	0.04	0.14	0.15	未来3天
	0.04	0.06	0.13	0.17	未来7天

[0124] 本发明建立的预测模型和预测方法可预测检测点的温度情况,该模型稳定性较好,优于传统的机器学习算法和时序模型,且该模型在不同层的表现能力相当,能够有效为粮食管理者提供辅助决策;同时,因粮食在储藏过程中,针对不同区域和仓型结构,粮食管理者可采取相对应的储存方法。

[0125] 显然,上述实施例仅仅是为清楚地说明所作的举例,而并非对实施方式的限定。对于所属领域的普通技术人员来说,在上述说明的基础上还可以做出其它不同形式的变化或变动。这里无需也无法对所有的实施方式予以穷举。而由此所引伸出的显而易见的变化或变动仍处于本发明创造的保护范围之内。




图1




图2




图3




图4




图5




图6




图7




图8




图9




图10




图11




图12