

粮情预测调研报告

电子科技大学 吴少智

2024 年 6 月 28 日

第一章 国内外粮情预测调研

1. 引言

粮食作为国家战略物资，其存储安全直接关系到国计民生和社会稳定。粮情监控与预测系统通过对粮食存储环境的实时监测，及时发现并处理潜在的安全问题。随着大数据、人工智能等技术的发展，粮情预测技术也在不断进步，为粮食安全管理提供了新的解决方案。粮情预测技术的研究涉及到多种算法和模型，包括基于 BP 神经网络的预测模型、基于 IPSO-GRU 网络的预测方法等。这些技术能够利用粮情监测系统实时采集的数据，预测储粮安全问题，有效提高预警能力。

2. 基于智能算法的粮情预测

2.1 基于门控循环单元（GRU）的粮温预测模型

GRU 模型作为一种先进的循环神经网络，能够有效处理和预测时间序列数据，适合于粮温这种具有明显时间依赖性的数据预测。为了降低模型复杂度并提高预测精度，有研究者采用了遗传算法（Genetic Algorithm, GA）和粒子群优化（Particle Swarm Optimization, PSO）相结合的方法来优化 GRU 模型的超参数。这些超参数包括隐层神经元的数量、批量大小等，通过 GA-PSO 算法的优化，可以更高效地搜索到最优的超参数组合。在 GRU 模型的基础上，进一步引入了注意力机制层。通过赋予不同时间步的输入数据不同的权重，模型能够更加精准地捕捉到影响粮温的关键因素。

神经网络	MAE	MSE	MAPE	R ²
GRU-Attention	0.046	0.003	0.291%	0.914
GRU	0.057	0.004	0.329%	0.895
LSTM-Attention	0.050	0.004	0.309%	0.904
LSTM	0.058	0.005	0.331%	0.899

图 1 对比实验验证结果

研究者通过实验验证了提出的 GA-PSO-GRU-Attention 模型在粮温预测任务上的有效性。实验结果显示，该模型在均方根误差（Mean Absolute Error, MAE）、

均方误差 (Mean Squared Error, MSE) 和决定系数 (R-squared, R2) 等评价指标上均表现优异, MAE 为 0.046, MSE 为 0.003, R2 为 0.914, 证明了模型预测的高精度和可靠性。

2.2 基于 GANPSO-BP 神经网络的粮情预测

粮食在储藏期间受多种因素影响, 其中温度是关键因素之一。准确预测粮堆内温度对预防粮食损失至关重要。《基于 GANPSO-BP 神经网络的粮情预测模型研究》文献中探讨了一种融合遗传算法和粒子群算法的改进 BP 神经网络模型在粮情预测中的应用。研究提出了一种新型的 GANPSO-BP 神经网络模型, 该模型结合了遗传算法和粒子群算法的优势, 通过优化 BP 神经网络的权值和阈值来提高预测精度。




图 2 GANPSO-BP 算法的流程图




图 3 部分实验结果图

实验使用了华东地区某粮库 2016 年的数据, 输入包括粮仓内外的温度、湿

度等参数，输出为粮堆底层平均温度的预测值。对比 BP 神经网络、PSO-BP 神经网络和 GANPSO-BP 神经网络的预测效果，结果显示 GANPSO-BP 神经网络在 MSE、MAE 和 MRE 等误差指标上均优于其他方法，具有更好的稳定性和准确性。GANPSO-BP 神经网络模型通过改进的惯性权重和遗传算法优化，在粮食温度预测方面显示出较高的性能，为粮食储藏安全管理提供了一种有效的技术手段。




图 4 部分实验结果图

2.3 基于优化 BP 神经网络的粮堆温度预测

粮堆温度预测对于保障粮食品质和安全具有关键作用。通过建立准确的粮堆温度预测模型，能够为粮食安全管理提供科学依据。粮食的呼吸作用、湿度、虫害、霉变以及粮仓结构等因素都会对粮堆温度造成影响。鉴于 BP 神经网络在处理复杂数据时的优越性，部分研究者选择了 BP 神经网络作为基础模型，并针对其泛化能力不强和容易陷入局部最优的问题，提出了两种改进方案：一是结合粒子群优化算法（PSO）来优化 BP 神经网络的权重和偏置，提高预测精度和模型的泛化能力；二是利用主成分分析（PCA）对原始数据进行降维和去噪处理，再通过 BP 神经网络进行温度预测，以提高模型的准确性和鲁棒性。

通过在河南省某粮仓的实际数据上进行实验验证，结果表明，与单一的 BP 神经网络模型相比，结合 PSO 的 BP 神经网络模型在预测准确率和均方根误差（RMSE）上均有显著提升。而结合 PCA 的 BP 神经网络模型在预测准确率和 RMSE 上表现更为优异，预测结果的均方误差降低了 3 倍，显示出更高的预测精度。

实际值	预测值 (BP)	准确率%	(PSO_BP)	准确率%
12.23	12.31791492	0.718846472	12.18281121	0.385844527
12.22	12.41975887	1.63468799	12.20270716	0.141512566
12.21	12.42727227	1.779461668	12.25552796	0.372874335
12.21	12.26946605	0.487027435	12.30103091	0.74554387
12.20	12.12860465	0.585207764	12.32835570	1.052095907

图 5 基于粒子群优化算法和 BP 神经网络组合预测的结果

2.4 基于宽度学习系统的仓储粮情预测

传统的预测方法往往只能从单一角度进行预测，难以全面评估粮情风险，而深度学习方法则面临训练样本需求量大、训练难度高、耗时长等挑战。针对这些问题，部分研究者采用了宽度学习的特征提取与融合方法，结合增量学习的训练策略，构建了一种新的预测模型。该模型利用粮情数据的多模态特征，在 BLS 现有框架的基础上进行改进，通过典型相关性分析(CCA)模块和特征融合节点，提高了预测精度。与传统深度学习模型相比，新模型在保证预测准确度的同时，显著减少了模型训练时间和难度，成为一种有效的替代方案。




图 6 仓储粮情风险预测模型框架

《基于宽度学习系统的仓储粮情风险点预测模型》文章中使用了 2019—2020 年岳阳市某国家级储备库的粮情测控数据，包括温度、湿度、虫情和气体成分等多模态数据。通过对数据的预处理和融合，建立了基于 BLS 的风险预测模型，并采用了增量学习算法 EIBLS 和 IIBLS 进行模型训练和更新。试验结果显示，增量学习算法能够显著提高模型的预测精度，尤其是在图像数据上，预测精度提

升更为明显。

预测模型算法	F_1	$G-mean$	训练时间/s
BiLSTM	0.87	0.89	722.67
Transformer	0.89	0.90	605.22
BLS	0.82	0.84	17.78
CFBLS	0.84	0.86	19.56
LCFBLS	0.86	0.88	20.33
EIBLS	0.87	0.88	16.48
IIBLS	0.88	0.89	48.51

图 7 预测效果对比

2.5 基于三维粮堆温度时空特性模型的粮情预测

三维粮堆的温度控制对于粮食的储存安全至关重要。传统的温度监测方法存在数据采集不全面、处理效率低等问题。有研究者通过构建三维粮堆温度的时空特性模型，旨在提高温度监测的精确度和效率，为粮食安全储存提供科学依据。

有研究者提出了一种基于泛克里金状态空间模型偏重于空间优化时空动态场估算方法（FUKSS）。该模型结合了状态克里金法和卡尔曼滤波，能够有效地描述时空数据的时空特征，并准确进行插值或估计。

FUKSS 算法估计:
初始化: $t=1, P_0 = \alpha K, c_0 = 0(n \times 1)$ 。
指定: $K, k(x), \alpha, R_t, F, W_t$ 。
状态方程:
$Z_t(x) = Z_{t-1}(x) + f^T(x)m_t + \varepsilon_t(x)$
观测方程: $Y_t(x) = Z_t(x) + v_t(x)$
循环计算从: $t = 1, \dots, T$
计算过程中的信息矩阵:
$L_t = (W_t P_{t-1} W_t^T + W_t K W_t^T + R_t)^{-1}$
$M_t = (F W_t^T L_t W_t F^T)^{-1} F W_t^T L_t$
$G_t = (P_{t-1} + K) W_t^T L_t (I - M_t^T F W_t)$
估计值:
$\hat{Y}_t(x) = k^T(x) K^{-1} \hat{c}_{t-1} + (k^T(x) K^{-1} G_t + f^T(x) M_t)(Y_t - W_t \hat{c}_{t-1})$
参数更新:
$P_t = (P_{t-1} + K)(I - W_t^T G_t^T)$
$\hat{c}_t = \hat{c}_{t-1} + G_t(Y_t - W_t \hat{c}_{t-1})$
循环结束

图 8 FUKSS 算法流程

FUKSS 模型显著特点在于能够处理粮堆空间的检测缺失和测量误差，研究

者通过模拟数据和实际粮仓的温度检测数据验证了模型的有效性。

2.6 基于机理驱动和数据驱动混合估计和预测模型

为提高对三维粮堆温度场的预测和估计精度，有研究者提出了一种结合机理驱动和数据驱动的方法，通过融合热传递机理模型和 FUKSS 模型，该混合模型能够有效处理数据缺失问题，并在一定程度上消除观测数据的噪声。

研究方法概括如下：

- 1. 机理驱动模型：使用简化的三维热力学模型描述由外部因素驱动的全局温度分布。
- 2. 数据驱动模型：利用 FUKSS 模型描述由内部因素引起的局部温度变化。
- 3. 混合模型构建：结合机理模型的全局趋势和 FUKSS 模型的局部变化，通过卡尔曼滤波方式对观测误差进行预测和校正。




图 9 混合模型流程图

研究者以青海互助县 3 号平方仓型数据为样本，验证了模型在处理高比例数据缺失时的有效性，且相较于 FUKSS 模型，混合模型显示出了更高的预测精度，更小的内存需求，更适用于实时监测和预测。

基于该模型可以研究进一步优化模型参数，提高对各向异性的描述能力，并探索更复杂的边界条件。

2.7 基于 R-FCN 的储粮害虫检测与粮情预测

储粮害虫是导致粮食产后损失的直接原因之一。传统的害虫检测方法依赖于人工识别，效率低下且易出错。随着图像监测技术的发展，基于深度学习的害虫

检测方法成为研究热点。有研究者提出基于区域全卷积网络（R-FCN）来实现储粮害虫检测模型构建，并进行了实验验证。




图 10 R-FCN 算法流程图




图 11 R-FCN 网络结构图

研究者通过国家粮食局研究院的帮助, 获得了8种常见储粮害虫的图像数据。对图像进行预处理, 包括去噪、增强和恢复与检测目标相关的信息。且为了提高模型的泛化能力和精度, 采用水平镜像、加入高斯噪声、调整图像亮度、旋转和裁剪等方法对训练集进行数据增强。

	AP(%)								mAP	detection
	TC	CF	CT	SO	SZ	RD	OS	LS	(%)	time(s)
R-FCN	87.05	84.37	81.42	82.18	79.94	90.87	87.69	88.73	85.28	0.122
R-FCN+	87.37	86.38	82.69	85.02	80.23	91.47	87.95	89.96	86.38	0.118
R-FCN++	88.35	86.74	83.17	85.23	81.45	92.75	88.53	90.67	87.11	0.118
R-FCN+++	88.94	87.25	83.24	86.36	84.63	93.71	89.32	91.05	88.06	0.118
R-FCN+++ (Dataset2)	~	~	~	80.74	78.16	~	~	~	79.45	0.118

图 12 研究者利用 DenseNet-121 改进模型的结果分析

研究者使用改进的 DenseNet 网络结构作为特征提取的基础，引入深度可分离卷积（Depthwise Separable Convolution）减少参数和计算量，提高训练速度。针对储粮害虫在图像中相对较小的特点，可以采用多尺度训练策略，提高模型对不同尺寸物体的检测能力。运用 Soft NMS 算法来解决重叠检测框问题，提高检测精度。

3. 总结

在本章的探讨中，我们对一系列前沿的粮情预测技术进行了综合评估，这些技术在提升粮食存储安全管理的预警能力方面展现出了显著的潜力。首先，基于 GRU 模型的粮温预测技术，通过融合遗传算法和粒子群优化，以及引入注意力机制，显著提升了对时间序列数据的处理能力。尽管该模型在训练过程中对计算资源的需求较高，且训练时间较长，但其在捕捉关键影响因素方面表现出的高精度，使其成为预测时间依赖性数据的理想选择。

进一步地，GANPSO-BP 神经网络模型通过整合遗传算法和粒子群算法的优势，对 BP 神经网络的权值和阈值进行优化，显著增强了预测的精度和稳定性。尽管这一模型在资源消耗上较为显著，但其在温度预测方面的卓越表现，特别是在需要高精度预测的场景中，确立了其作为理想选择的地位。此外，优化 BP 神经网络的方法，结合粒子群优化和主成分分析，虽然在处理复杂数据集时可能面临效率挑战，但其在提升模型泛化能力和准确性方面的贡献，使其在构建精确粮堆温度预测模型方面具有重要价值。

在探索更为高效的预测策略时，宽度学习系统和基于三维粮堆温度时空特性的模型，通过特征提取与融合以及增量学习策略，有效降低了模型训练的复杂性和时间需求。这些方法在需要快速响应和处理多模态数据的情境中，显示出了其独特的适用性。同时，机理驱动和数据驱动的混合模型，通过结合热传递机理和 FUKSS 模型，不仅有效处理了数据缺失问题，而且在提高预测精度方面取得了显著进展，特别适合于实时监测和预测的应用场景。最后，基于 R-FCN 的害虫检测与粮情预测技术，利用深度学习提升了害虫检测的效率和准确性，为害虫检测和相关粮情预测提供了强有力的技术支持。

综合考虑，这些粮情预测技术各有所长，选择最合适的模型需基于实际应用场景、数据特性及计算资源等因素进行细致权衡。例如，宽度学习系统在处理多

模态数据和需要快速预测的场景中表现出色；而 GANPSO-BP 神经网络则在追求高精度和稳定性的预测任务中更为合适。通过这些技术的精心应用，不仅可以显著提高粮食存储安全管理的技术水平，还能有效增强预警系统的响应能力。

第二章 温度场精细化重建

1. 需求描述与难点分析

需求：需要对粮仓内的温度分布进行精细化重建，从一个初始分辨率较低且数据稀疏的 $5\text{m} \times 5\text{m} \times 2\text{m}$ 温度数据矩阵出发。目标是将温度场细化至更高分辨率，具体到 $0.5\text{m} \times 0.5\text{m} \times 0.2\text{m}$ 的级别，以更准确地捕捉粮仓内部的温度变化和分布情况。

难点：

- i. **数据稀疏性：**原始温度数据的分辨率较低，且数据点稀疏。这使得直接推断和重构高分辨率温度场具有挑战性，因为缺乏足够的直接测量数据来支持高分辨率的重构。
可能的解决方法：图信号处理（GSP），利用 GSP 技术在表示传感器位置空间关系的图上对稀疏温度数据进行插值和平滑处理。机器学习模型，采用高斯过程（GP）或神经网络等机器学习模型，学习空间相关性并插补缺失的数据点。
- ii. **非线性复杂性：**粮仓内的温度分布受到多种因素的影响，如通风、湿度、粮食种类和堆积方式等。这些因素导致温度场具有复杂的非线性变化，增加了重构的难度。
可能的解决方法：变分自动编码器（VAE）和生成模型，使用 VAE 或其他生成模型来捕捉温度数据的底层分布，并建模复杂的非线性关系。混合模型，结合包含已知影响温度分布因素的物理模型和数据驱动模型，以捕捉理论和经验模式。
- iii. **实时性要求：**为了实现实时监控，重构算法需要在较短的时间内处理和计算大量数据。这需要高效的计算方法和优化算法。
可能的解决方法：边缘计算，利用边缘计算在传感器节点附近进行数据处理，减少实时监控的延迟和带宽需求。并行和分布式计算，利用并行和分布式计算框架加快大数据集的处理速度。

2. 相关工作和可能的解决方案

为了有效地解决粮仓温度场精细化重构中的难题，实现准确、实时的温度监控，需要结合相关的研究工作情况，以下主要从各种数据缺失推理模型为主进行分析。首先是传统的方法介绍：

插值技术被广泛用于根据已知数据点估算未取样位置的数值。近邻插值和线性插值等传统方法简单且计算效率高，但往往无法捕捉大型粮仓内复杂的温度变

化。更复杂的方法，如双线性插值和双三次插值，可提供更平滑的结果，但仍难以解决温度场的非线性特征。样条插值法（包括三次样条插值法和 B 样条插值法）可提供更好的平滑性和连续性，因此适用于更复杂的温度分布。不过，这些方法对大型数据集的计算量较大。克里金插值法是另一种对温度数据的空间相关性进行建模的先进技术。这种地质统计方法可提供最佳的线性无偏预测，但需要对空间相关结构有透彻的了解，而这给精确建模带来了挑战性。

显然，面对上述分析的四个难点，需要更新颖的方法来提供解决方案。

混合方法：将物理模型与机器学习方法相结合，可以提高温度场重建的准确性和鲁棒性。这些混合方法充分利用了数据驱动技术和特定领域知识的优势。例如，将热传导方程纳入神经网络框架可提高网络准确预测温度分布的能力，Karpatne 等人[1] 使用科学知识指导神经网络的构建和学习，提出了一个框架被称为 Physics-Guided Neural Networks (PGNN) 物理引导神经网络，证明了该框架在湖泊温度建模问题上的有效性。

基于 Graph Signal Processing (GSP)图信号处理的方法：图信号处理是一个新兴领域，它将经典的信号处理技术扩展到图上定义的数据。这种方法特别适用于处理间距不规则的数据和捕捉复杂的空间关系。Jiang 等人[2]提出了一种基于图学习的数据恢复方法，用于插补时空传感器数据中的缺失值，实验结果表明，其提出的基于图的方法在传感器数据插补方面具有优越的性能，尤其是在丢失大量传感器数据时。




图 1：基于图学习的数据恢复方法。

基于 GNN 和 Transformer 的方法：GNN 擅长捕捉局部空间依赖关系和图结构，而 Transformer 则在处理长程依赖关系和序列建模方面功能强大。将 GNN 与 Transformer 相结合，可以充分利用两种架构的优势，有效地重建复杂环境中的温度场。Zhang 等人[4] 提出了 Graph Transformer-based Traffic Data Imputation (GT-TDI) 基于 Graph Transformer 的交通数据插补模型，通过利用对道路网络的时空语义理解来插补大量交通数据中的缺失值。此外，还采用了大语言模型 (LLM) 和提示工程，以实现与交通数据插补系统的自然和直观的交互。




图 2 GT-TDI 基本框架示意图

基于 **Variational Autoencoders (VAE)** 变分自动编码器的方法：变分自动编码器 (VAE) 是一种生成模型，可以学习数据的概率表示。通过学习温度数据的基本分布，它们对重建温度场中的缺失值特别有用。Boquet 等人[5]提出了一种用于道路交通预测系统的 VAE 解决方案，在此框架下提出了一种在线无监督估算方法，用于处理缺失值的未观测交通数据。

3. 总结

在解决粮仓温度场精细化重建的挑战中，关键问题包括数据稀疏性、非线性复杂性和实时性要求。为了有效应对这些问题，从其他类似的数据缺失推算模型上寻找了一些解决方案，如图信号处理、变分自动编码器、GNN 与 Transformer 的结合，以及混合物理模型和数据驱动模型。这些方法不仅能够处理复杂的温度场特征和空间关系，还能在较短时间内实现准确和实时的温度监控和重构。

第三章 3D 目标检测

1.任务描述

3D 目标检测旨在预测 3D 空间中关键目标的位置、大小和类别，例如机动车、行人、骑自行车的人等。与仅在图像上生成 2D 边界框并忽略目标与本体的实际距离信息的 2D 目标检测相比，3D 目标检测侧重于对真实世界 3D 坐标系中目标的定位和识别。

传感器输入作为原始数据。相机和 LiDAR（激光雷达）、核磁共振

2. 3D 目标检测与粮情预测的关系

2.1 数据结构的相似性

(1) 温度矩阵：在粮仓管理中，监测粮仓内不同位置的温度数据是确保粮食安全的重要手段。这些温度数据可以看作是一个多维矩阵。例如，粮仓可以被分成不同的格子，每个格子记录一个温度值，这样我们就得到了一个三维矩阵，其维度分别代表粮仓的宽度、高度和深度。通过分析这个温度矩阵，我们可以实时监控粮仓内部的温度分布，发现可能存在的异常情况。

(2) 色彩矩阵 (图像数据)：如果使用热成像仪获取粮仓内的温度分布情况，这些图像数据可以被转换为色彩矩阵。每个像素的颜色代表该位置的温度值。通过处理这些图像数据，我们不仅可以直观地看到温度的分布情况，还可以应用图像处理技术来分析和预测温度变化。这种方法与处理图像数据的方式类似，可以利用已有的图像处理算法，如边缘检测、区域分割等，来识别温度异常区域。

2.2 处理方法可类比性

(1) 时间序列分析

3D 目标检测：在自动驾驶任务中，3D 目标检测通常需要处理连续的点云帧数据。这些点云数据不仅包含空间信息，还包含时间维度的信息。通过结合时间序列数据，我们可以更准确地检测和跟踪目标。例如，连续的点云帧可以帮助我们理解物体的运动轨迹，从而提高检测的准确性和鲁棒性。

粮情预测：温度数据通常是时间序列数据，通过时间序列分析，我们可以预测未来的温度变化。例如，利用时间序列模型（如 MAMBA、LSTM 等），我们可以分析历史温度数据，识别温度变化的模式和趋势，从而预测未来的温度变化。这对于防范粮仓内部的温度异常具有重要意义，可以提前采取应对措施，确保粮食安全。

(2) 区域建议网络 (RPN)

3D 目标检测：在 3D 目标检测中，区域建议网络 (RPN) 用于生成候选区域，这些候选区域是可能存在目标物体的位置。RPN 通过分析输入数据（如点云数据或图像数据），生成一系列候选框，这些候选框可以显著减少后续处理的计算量，并提高目标检测的效率和准确性。

粮情预测：在粮情预测中，我们可以借鉴 RPN 的思想，设计出类似的方法来检测温度异常区域。例如，通过分析温度矩阵或热成像图像，我们可以生成一系列候选区域，这些区域可能存在温度异常。然后，我们可以对这些候选区域进行深入分析，确定是否存在潜在的风险点。这种方法可以帮助我们更高效地识别和预测粮仓内部的温度异常情况，及时采取措施防止粮食变质。

3.数据集

目前 3D 目标检测的数据集在自动驾驶任务上居多。

4.评价指标

判断框是否预测正确，IoU 交并比、阈值。

$$\begin{aligned} \text{精确率: } Precision &= \frac{TP}{TP + FP} \\ \text{召回率: } Recall &= \frac{TP}{TP + FN} \end{aligned}$$

精确率 (Precision) 表示检测器找出的框有多少是对的，衡量误检程度。召回率 (Recall) 表示检测器找出的正确框占 ground truth 的百分之多少，衡量漏检程度

AP (Average Precision): P-R 曲线积分后的结果。

mAP (mean Average Precision): 多种类平均 AP

5.模型分类


5.1 基于 2D 特征

基于结果提升的方法 (Result Lifting-based Methods): 输入 2D 特征，检测目标的 2D 信息 (位置、方向、深度)，再将 2D 检测结果提升到 3D 空间，得到最终的检测结果。总体上可以采用 2D 图像检测的方法，在结果上学习深度值得到 3D 检测结果。

(1) Region-based methods


也就是二阶段方法，在第一阶段生成 proposal 区域，在第二阶段引入深度空间信息。

根据图像差异学习深度信息：如图表 1 所示，与大多数现有方法中把距离作为一个单一变量进行回归不同，改文章提出了一种新的基于几何的距离分解，以恢复其因子的距离。该分解将物体的距离分解为最具代表性和稳定性的变量，即物理高度和图像平面上的投影视觉高度。



图表 1 图像差异学习深度信息

使用现成的深度估计器：如图表 2 所示，通过两个分支，包括三维检测分支（蓝色）和深度特征提取分支（绿色）。黄色的 DDMP 模块揭示了深度条件下的动态信息传播。它动态地对上层图像分支中的上下文感知节点进行采样，并根据底层分支的多尺度深度特征预测混合滤波器的权重和亲和力，用于信息传播。




图表 2 使用现成的深度估计器

(2) Single-Shot methods

不分阶段（实际意义为统一的损失优化贯穿全局的），得到类别预测同时得到 proposal 区域。


anchor-based 方法：先验知识，给定具有先验知识的 anchor 作为特定类别的检测框。如图表 3 所示，在本文中提出并整合了 GrooMeD-NMS（一种新的极大

值抑制方法), 提出了一种用于单眼 3D 物体检测的新型分组数学可微分 NMS, 这样, 网络在 NMS 后对盒子进行了端到端的训练, 只用同一个损失。



图表 3 anchor-based 方法

anchor-free 方法: 无先验知识, 根据目标中心点确定目标位置, 再使用几个平行头学习目标的其他属性 (深度、尺寸、方向)。如图表 4 所示, 提出了一个灵活的单眼三维物体检测框架, 该框架明确地将截断的物体解耦, 并自适应地结合多种物体深度估计的方法。具体来说, 将预测长尾截断物体的特征图的边缘解耦, 这样正常物体的优化就不会受到影响。此外, 将物体深度估计表述为直接回归物体深度和解决不同关键点组的深度的不确定性引导的集合。



图表 4 anchor-free 方法

5.2 基于 3D 特征


主要思想是主体部分在 3D 空间内得到 3D 检测结果。

(1) Feature Lifting-based methods

输入图像得到 2D 图像特征, 再转换为 3D 体素特征, 之后得到 3D 的检测结果。重点在于转换为 3D 体素的方法。

单眼提升 **monocular methods:**


如图表 5 所示，本文贡献了 BEVDet 模型。BEVDet 在鸟眼视图（BEV）中进行三维物体检测，大多数目标值都是确定的，路线规划可以方便地进行。BEVDet 只是重新使用现有的模块来建立其框架，但通过构建一个专属的数据增强策略和升级非最大抑制策略来大幅发展其性能。



图表 5 单眼提升任务下的基于特征提升方法

立体提升 **stereo methods:**

如图表 6 所示，改模型通过在可微分的体积表示上检测三维物体，大大减少了与 LiDAR 方法差距。三维几何体有效地编码了三维规则空间的三维几何结构。通过这种表示方法，该模型同时学习深度信息和语义线索，同时首次提供了一个简单而有效的基于立体的单阶段三维检测管道，该管道以端到端学习的方式联合估计深度并检测三维物体。




图表 6 立体提升任务下的基于特征提升方法

(2) Data Lifting-based methods

二维输入图像直接转换为三维的数据（点云 point cloud），提取三维特征，推理得到检测结果。The pseudo-LiDAR pipeline: 根据二维图像得到深度图，从而计算出三维坐标得到三维的点云，之后采用现行的激光雷达方法目标检测。重点在于计算深度图的方法。

如图表 7 所示，伪激光雷达（pseudo-LiDAR）通过将二维深度图输出转换为

三维点云输入, 将最先进的用于三维深度估计的深度神经网络与用于三维物体检测的网络相结合。在该文章中, 引入了一个基于可区分的表征变化 (CoR) 模块的新框架, 允许整个 PL 的 pipeline 进行端到端的训练。



图表 7 基于数据提升的方法